KL散度 & GRPO中使用的注意事项

> 本文是对该文章的简化
> https://xihuai18.github.io/reinforcement-learning/2025/12/01/kl-estimators-zh.html

导读

GRPO中KL散度的作用：防止和初始化的参数 π_{ref} 相差太远，导致灾难性遗忘（ π_{ref} 通常是SFT训练好的模型，如果和 π_{ref} 相差过远，可能会丢失LLM的通用能力，甚至生成乱码）

> 但实践中往往不使用KL散度，甚至后续的DAPO、GSPO明确去掉了KL散度

关于KL散度，深挖下去有很多值得单独探讨的东西，但和GRPO的公式本体关联不大，因此单独作为一篇文档。

本文结构：

- KL散度的本质含义：非最优编码下，额外的平均编码长度
- KL散度的性质：（1）单个样本可以为负，但整体期望非负；（2）非对称性
- 两种KL散度：
  - 监督学习用正向KL散度：从固定数据集采样
  - 强化学习用逆向KL散度：从实时更新的 π_θ 采样
- KL散度的求导：最基本的k1估计
- KL散度的其他估计方式：k2、k3估计
  - k1估计的缺点：无偏差，高方差
  - k2估计：有较小的偏差，但低方差
  - k3估计：无偏差、低方差（因此GRPO使用k3估计来计算KL散度）
  - k1+、k3+估计：在k1、k3估计中，用于修正某些简化代码实现的bug
- KL散度=交叉熵-策略熵
  - KL散度：额外编码长度的均值
  - 交叉熵：非最优编码方案的长度均值
  - 策略熵：最优编码方案的长度均值

TL&DR：GRPO中的KL散度的注意事项

在GRPO中使用KL散度要注意一些细节（先给结论，后面再解释）

- KL散度的“方向”：是 $\mathrm{KL}(\pi_\theta|\pi_{ref})$ ，而不是$\mathrm{KL}(\pi_{ref}|\pi_\theta)$
- KL散度出现的位置：出现在目标函数的正则项上，而不是reward上
- KL散度的实际计算方式：使用 k_3 估计，而不是原始定义

KL散度公式的由来

> 本章概要：
>
> - KL散度在机器学习中常用于衡量两个分布的差异。但KL散度的本质含义是什么？
> - 本章从信息论的角度解读：KL散度是**非最优编码**导致的**额外编码长度**的**平均值**
> - KL散度作为机器学习目标：通过**减少额外编码长度**，来拉近两个分布

KL散度公式：

$$\mathrm{KL}(P||Q) = \mathbb{E}_{x\sim P(x)}\left[\log\frac{P(x)}{Q(x)}\right] = \sum_x P(x)\cdot\log\frac{P(x)}{Q(x)}$$

信息论的解释：

- **最优编码方案**：每个概率分布都对应一种最优的（最短的）编码方案
  - 分布 $P(x)$ 和 $Q(x)$ 各有其最优编码方案（编码最短的方案）
  - 即使对同一事件 x，在 P 和 Q 的最优方案下，其编码长度也可能不同
  - 没有脱离具体概率分布的“绝对最优”编码方案。一个编码方案在分布 P 下最短，就一定在 Q 下不是最短
- **最优编码长度**： $-\log P(x)$
  - 在分布 $P(x)$ 下，描述事件 x 所需的最短编码长度（信息量）为 $-\log P(x)$。
  - 事件概率越大，所需编码长度越短：
    - 高频实体通常有简称（例：“特朗普”默认指美国总统特朗普）
    - 低频实体则需要更长的全名或描述来区分（例：“我家楼下那个叫特朗普的厨师”）
  - 同一事件 x 在不同分布下，编码长度不同：
    - 在机器学习社区内，默认用“lr”指代“learning rate”，编码很短
    - 对普通大众，则需要完整写出“learning rate”并加以解释，编码很长

        - 这对应了不同的语言模型（概率分布），事件 x（指代“学习率”这个词）在不同人群中的出现概率不同
- **单个事件的额外编码长度**：$\log \frac{P(x)}{Q(x)}$
    - 在 P 和 Q 的最优编码方案下，x 的编码长度分别为 $-\log P(x)$ 和 $-\log Q(x)$
    - 若使用 Q 的方案编码 x，相比使用 P 的方案，多出的长度为：$(-\log Q(x)) - (-\log P(x)) = \log \frac{P(x)}{Q(x)}$
- **额外长度的期望**：$\mathbb{E}_{x\sim P(x)}\left[\log \frac{P(x)}{Q(x)}\right]$
    - 如果事件 x 是从概率 $P(x)$ 采样的，却**强行**采用分布 $Q(x)$ 的最优编码方案，那么相比使用 P 的方案，平均需要额外付出多长的编码？
    - 这个额外的平均长度正是 $\mathbb{E}_{x\sim P(x)}\left[\log \frac{P(x)}{Q(x)}\right]$，也就是 **KL散度$\mathrm{KL}(P||Q)$的定义**。
- **一句话记住KL散度**：
    - $\mathrm{KL}(P||Q)$：从分布 P 中采样，但用 Q 的方案编码，相比用 P 的方案编码，需要**平均多付出**的编码长度
- **KL散度作为优化目标的本质**：
    - 通过缩短两种编码方案的长度差异，来使两个分布更相似
    - （不需要真的进行编码并比较长度，最优长度 $-\log P(x)$ 已经通过信息论给出了）
- **KL散度的性质**：
    - **非负性**：$\mathrm{KL}(P||Q) \geq 0$，当且仅当 $P = Q$ 时取等
    - **非对称性**：$\mathrm{KL}(P||Q) \neq \mathrm{KL}(Q||P)$

KL散度的理解

- **非负性**：
    - **对单个样本**，额外长度 $\log \frac{P(x)}{Q(x)}$ **可以为负**（当 $Q(x) > P(x)$ 时，Q 的编码更短）。
    - 但其**期望值** $\mathbb{E}_{x\sim P(x)}\left[\log \frac{P(x)}{Q(x)}\right]$ **非负**。
    - **本质原因**：
        - 如果数据来自 P，那么理论上为 P 设计的最优编码方案具有最短的**平均**编码长度
        - 如果使用为 Q 设计的最优方案来编码，虽然对某些 x 可能更短，但对另一些 x 会变得更长。而其平均长度，在概率 Q 下会更短，在概率 P 下会更长
- **非对称性**：
    - 从P采样、用Q编码的额外平均长度 ≠ 从Q采样、用P编码的额外平均长度
    - 两者都是正值，但不相等
    - 不容易直观理解，但知道两个代价确实不相等即可
- **如果从 Q 采样会怎样？**
    - $\mathbb{E}_{x\sim P(x)}\left[\log \frac{P(x)}{Q(x)}\right] = \sum_x P(x) \cdot \log \frac{P(x)}{Q(x)} = \mathrm{KL}(P||Q)$

        - 意义：从P采样时，“用Q编码”相比“用P编码”所增加的平均长度
    - $\mathbb{E}_{x\sim Q(x)}\left[\log\frac{P(x)}{Q(x)}\right]=\sum_x Q(x)\cdot\log\frac{P(x)}{Q(x)}=-\sum_x Q(x)\cdot\log\frac{Q(x)}{P(x)}=-\mathrm{KL}(Q||P)$
        - 意义：从Q采样时，“用Q编码”相比“用P编码”所增加的平均长度（但用Q编码反而更短，因此“增加的长度”是负的，所以有个负号）

> 从信息论的角度看机器学习：
>
> - 监督学习：如果P是数据的真实分布，Q是模型，则用Q逼近P，一定会和P有差距
> - 知识蒸馏：$\mathbb{P}$ 是真实数据分布，P是教师模型，Q是学生模型，则用Q拟合P一定不会比P做得更好，除非Q同时还在拟合 $\mathbb{P}$
> - 没有免费午餐：在分布P下的最优模型，一定不是分布Q下的最优模型，没有“绝对最优”的模型

机器学习中的两种KL散度

> 本章概要：正向KL散度（监督学习） vs 反向KL散度（强化学习）

前面说过KL散度作为机器学习目标函数的意义：

- 通过缩短概率 P,Q 下最优编码的长度差异，来使两个分布更相似
- 但不需要实际进行编码并统计长度，信息论直接给出了最优编码长度

但在具体计算上，对于固定的分布 $P(x)$ 和含参数、可学习的分布 $P_\theta(x)$ ，会出现两种KL散度的计算方式：

- 正向KL散度： $\mathrm{KL}(P||P_\theta)=\mathbb{E}_{x\sim P(x)}\left[\log\frac{P(x)}{P_\theta(x)}\right]=\sum_{\text{遍历所有}x}P(x)\cdot\log\frac{P(x)}{P_\theta(x)}$
- 逆向KL散度： $\mathrm{KL}(P_\theta||P)=\mathbb{E}_{x\sim P_\theta(x)}\left[\log\frac{P_\theta(x)}{P(x)}\right]=\sum_{\text{遍历所有}x}P_\theta(x)\cdot\log\frac{P_\theta(x)}{P(x)}$

核心差别：数据从哪采样

- 正向KL散度 $\mathrm{KL}(P||P_\theta)$ ：数据从固定的 P 采样，并用一直更新的 P_θ 编码
    - 对应场景：监督学习，从数据集D（对应固定的 P ） 采样，用一直更新的模型 P_θ 编码
- 逆向KL散度 $\mathrm{KL}(P||P_\theta)$ ：数据从一直更新的 P_θ 采样，用固定的 P 编码
    - 对应场景：强化学习，数据从一直更新的策略 π_θ 采样（rollout），用固定的策略 π_{ref} 编码

> 如何记住哪个叫正向、哪个叫逆向：
>
> - 因为监督学习更常见，所以才将最常用的 $\mathrm{KL}(P||P_\theta)$ 称为正向
> - 把最常见的称为正向，本质也是信息论“概率大对应编码短”的体现

以上解释了为什么 GRPO 中要使用逆向KL散度 $\mathrm{KL}(\pi_\theta||\pi_{ref})$

- 因为数据是从实时更新的 π_θ rollout的
- off-policy也不改变本质：虽然操作上是从 π_{old} 采样，但经过重要性采样 $\frac{\pi_\theta}{\pi_{old}}$ 修正后，本质上等价于从 π_θ 采样

更深刻地理解，为什么监督学习用 $\mathrm{KL}(P||P_\theta)$ ，强化学习用 $\mathrm{KL}(P_\theta||P)$ ？

- 监督学习：
  - 数据分布 P 是固定的，模型 P_θ 是随机初始化的
  - 初始时 $P_\theta \neq P$ ，且 P 是更“好”的
  - 所以我们从更好的 P 采样，并且让 P_θ 不断向 P 逼近，最终达到 $P_\theta \approx P$ 的效果
- 强化学习：
  - π_θ 和 π_{ref} 是以相同的SFT模型初始化的，只不过 π_θ 后续一直更新，而 π_{ref} 固定不动
  - 初始时， $\pi_\theta = \pi_{ref}$ ，但在RL训练过程中， π_{ref} 固定不变，而 π_θ 越来越“好”
  - 所以我们从更好的 π_θ 采样，让 π_θ 在更新过程中不要和 π_{ref} 越拉越远 （防止灾难性遗忘）
- 总结：
  - 都是从“更好”的分布中采样：
    - 监督学习中数据集 P 更好，强化学习中新策略 π_θ 更好
  - 方向相同：
    - 都是 P_θ 和 P 之间的“吸引力”
  - “动力学”相反：
    - 监督学习中，KL散度是参数更新的“动力”，来让P_θ 逼近 P
    - 强化学习中，KL散度是参数更新的“阻力”，防止 π_θ 和 π_{ref} 越拉越远

两种KL散度的效果差异：
抛开具体的监督学习、强化学习场景，两种KL散度本身的性质也有差异

- 例：假设 P 是多个高斯分布的和（有多个峰），P_θ 是单个高斯分布（只有一个峰，但μ和σ是可学习的参数），让 P_θ 拟合 P
- 正向KL散度 $\mathrm{KL}(P||P_\theta)$
  - 效果：P_θ 会变成一个**宽而扁**的峰，把 P 的所有峰都包起来
  - 原因：数据从P采样，所有峰都会被采出来，P_θ 要兼顾所有峰
- 逆向KL散度 $\mathrm{KL}(P_\theta||P)$ ：
  - 效果：P_θ 会变成一个**窄而尖**的峰，去拟合 P 最大的峰，忽略其他小峰
  - 原因：数据从 P_θ 采样，一个峰越来越大，采样频率越来越高

这也是GRPO使用 $\mathrm{KL}(\pi_\theta||\pi_{ref})$ 的另一个原因：希望通过GRPO增强某一方面的能力（加强某个峰），而不是像初始化的SFT一样杂而不精（囊括所有大小峰）

KL散度的求导

> 本章概要：
> 为什么监督学习中的正向KL散度能直接求导，而强化学习的反向KL散度求导要整很多花活（在GRPO中采用k3估计）

正向KL散度求导（简单）

- 正向KL散度：$\mathrm{KL}(P||P_\theta) = \mathbb{E}_{x\sim P(x)}\left[\log \frac{P(x)}{P_\theta(x)}\right]$
- 这是个典型的 $\mathbb{E}_{x\sim P(x)}[f_\theta(x)]$ 型机器学习问题，分布 $P(x)$ 中不含参数，打分函数 $f_\theta(x)$ 含参数
- 直接 $\nabla_\theta \mathrm{KL}(P||P_\theta) = \mathbb{E}_{x\sim P(x)}[\nabla_\theta f_\theta(x)]$ 求导即可，不用整很多花活
- 监督学习中基本都是正向KL散度

逆向KL散度求导（复杂）

- 逆向KL散度：$\mathrm{KL}(P_\theta||P) = \mathbb{E}_{x\sim P_\theta(x)}\left[\log \frac{P_\theta(x)}{P(x)}\right]$
- 这是很罕见的 $\mathbb{E}_{x\sim P_\theta(x)}[f_\theta(x)]$ 型机器学习问题，分布 $P_\theta(x)$ 和打分函数 $f_\theta(x)$ 中含参数，处理非常麻烦
- 处理方法：
  - GRPO推导策略梯度时，介绍过此技巧：“广义的”重参数化方法
  - 找到另一个满足条件的无参数分布 $Q(x)$ 和含参数打分函数 $g_\theta(x)$ 。需要满足的条件：
    - $\mathbb{E}_{x\sim P_\theta(x)}[f_\theta(x)] = \mathbb{E}_{x\sim Q(x)}[g_\theta(x)]$
    - $Q(x)$ 无参数， $g_\theta(x)$ 和 $P_\theta(x)$ 、$f_\theta(x)$ 共享相同的参数θ
  - 此时 $\nabla_\theta \mathrm{KL}(P_\theta||P) = \mathbb{E}_{x\sim Q(x)}[\nabla_\theta g_\theta(x)]$ ，也能直接求导了
- 因此GRPO（以及很多强化学习中）要用很麻烦的方式来处理KL散度

forward & backward 结果

推导过程太麻烦了，直接给结论。

正向KL散度（SFT）

- forward：$\mathrm{KL}(\pi_{ref}|\pi_\theta) = \mathbb{E}_{\tau\sim\pi_{ref}}\left[\log \frac{\pi_{ref}}{\pi_\theta}\right]$
- backward：$\nabla_\theta \mathrm{KL}(\pi_{ref}|\pi_\theta) = \mathbb{E}_{\tau\sim\pi_{ref}}\left[-\nabla_\theta \log \pi_\theta\right]$
- 其中 $\mathbb{E}_{\tau\sim\pi_{ref}}[\cdot] \approx \frac{1}{N}\sum_{\substack{\text{从}\pi_{ref}\text{采样} \\ N\text{个}\tau}}(\cdot)$

逆向KL散度（GRPO）

- forward： $\mathrm{KL}(\pi_\theta|\pi_{ref}) = \mathbb{E}_{\tau\sim\pi_\theta}\left[\log\frac{\pi_\theta}{\pi_{ref}}\right] = \mathbb{E}_{\tau\sim\pi_{old}}\left[\frac{\pi_\theta}{\pi_{old}}\log\frac{\pi_\theta}{\pi_{ref}}\right]$
- backward： $\nabla_\theta\mathrm{KL}(\pi_\theta|\pi_{ref}) = \mathbb{E}_{\tau\sim\pi_{old}}\left[\frac{\pi_\theta}{\pi_{old}}\log\frac{\pi_\theta}{\pi_{ref}}\nabla_\theta\log\pi_\theta\right]$
- 其中 $\mathbb{E}_{\tau\sim\pi_{old}}[\cdot] \approx \frac{1}{N}\sum_{\substack{\text{从}\pi_{old}\text{采样}\\ N\text{个}\tau}}(\cdot)$

> 以上是off-policy下，“广义的”重参数化的结果
>
> - 其中无参数的分布 $Q = \pi_{old}$ ，有参数的新打分函数 $g_\theta = \frac{\pi_\theta}{\pi_{old}}\log\frac{\pi_\theta}{\pi_{ref}}$
> - 如果是on-policy，把所有 π_{old} 换成 $\pi_{\theta.detach}$ 即可

以上是最“原教旨主义”的逆向KL散度的求导。

- 但实际上， g_θ 还有其他的构造方式，并且也能满足 $\mathbb{E}_{x\sim P_\theta(x)}[f_\theta(x)] = \mathbb{E}_{x\sim Q(x)}[g_\theta(x)]$
- 但是其他构造方式有更好的数学性质：方差更小
- 本章“原教旨主义”的 g_θ 构造方式叫做**k1估计**，而下一章介绍的其他构造方式就是k2、k3估计

特殊情况：一条样本的“KL散度”

> 该结论用于在下一章分析，为什么k1估计方差高

- 特殊之处：在 $\mathbb{E} \approx \frac{1}{N}\sum_{N\text{个采样}}$ 的转换中 $N = 1$
- 以下是on-policy的版本，off-policy把 $\pi_{\theta.detach}$ 换成 π_{old}
- 正向KL散度：
  - forward： $\mathrm{KL}(\pi_{ref}|\pi_\theta) = \mathbb{E}_{\tau\sim\pi_{ref}}\left[\log\frac{\pi_{ref}}{\pi_\theta}\right] \approx \log\frac{\pi_{ref}}{\pi_\theta}$
  - backward： $\nabla_\theta\mathrm{KL}(\pi_{ref}|\pi_\theta) = \mathbb{E}_{\tau\sim\pi_{ref}}\left[-\nabla_\theta\log\pi_\theta\right] \approx -\nabla_\theta\log\pi_\theta$
- 逆向KL散度：
  - forward： $\mathrm{KL}(\pi_\theta|\pi_{ref}) = \mathbb{E}_{\tau\sim\pi_\theta}\left[\log\frac{\pi_\theta}{\pi_{ref}}\right] \approx \log\frac{\pi_\theta}{\pi_{ref}}$
  - backward： $\nabla_\theta\mathrm{KL}(\pi_\theta|\pi_{ref}) = \mathbb{E}_{\tau\sim\pi_{\theta.detach}}\left[\frac{\pi_\theta}{\pi_{\theta.detach}}\log\frac{\pi_\theta}{\pi_{ref}}\nabla_\theta\log\pi_\theta\right] \approx \frac{\pi_\theta}{\pi_{\theta.detach}}\log\frac{\pi_\theta}{\pi_{ref}}\nabla_\theta\log\pi_\theta$
- 单条样本 x 计算的 “KL散度”，即 $\log\frac{P(x)}{Q(x)}$ ，实际是“点对点信息差异”，也就是最优编码的长度差异

KL散度的估计

> 本章概要：

> - 上一章介绍了最基本的KL散度估计方法（k1估计），本章继续介绍另外两种估计方法：k2、k3估计
> - k2、k3估计的本质是与k1不同的 g_θ 构造方法
> - k1估计的特点：无偏差，但高方差
> - k2估计：用低偏差换取低方差；k3估计：不仅低方差，而且无偏差
> - GRPO中通常使用k3估计

监督学习中的正向KL散度不再赘述，只讲GRPO中的逆向KL散度。

k1估计的缺点：高方差

虽然上面给出了逆向KL散度的公式（称为k1估计），但该公式实际中不好用。

- 原因：高方差
- 什么是方差：
  - $\mathbb{E}_{\tau\sim P(\tau)}[\cdot] = 方差 + \frac{1}{N}\sum_{\substack{从P(\tau)采样\\N个\tau}}(\cdot) \approx \frac{1}{N}\sum_{\substack{从P(\tau)采样\\N个\tau}}(\cdot)$
  - 方差：“期望”和“采样平均”之间的差值（所以才是约等于）
  - 高方差：“期望”和“采样平均”之间的差值，随采样波动大
- 高方差的直观体现：
  - KL散度根据定义，理论上一定是非负的
  - 但用采样算出的KL散度，**有可能是负的**（说明此时方差特别大）
  - 为什么会采样出负的：
    - KL散度本质是“用 π_{ref} 编码产生的额外长度”的期望值
    - 单条数据的额外长度 $\log\frac{P(x)}{Q(x)}$ 可以是负的（此时 $\pi_{ref} > \pi_\theta$ ）
    - 如果采样到这样的数据偏多，均值也可能是负的
    - 本质是采样的数据不够多，但计算资源有限很难大量rollout
  - 期望非负 → 单条样本可能是负的 → 此类样本多，则平均值也是负的 → 理论上期望非负，实际的平均值却是负的 →方差大
- 如果KL散度是负的会发生什么：
  - GRPO的目标：极大化“强化学习优势-KL散度”，但“-KL散度”变成正值了
  - 不管强化学习的优势，进一步降低 π_θ （KL散度会变得更负，即-KL散度变得更正），就能无脑刷高目标函数了
  - 结果：灾难性遗忘， π_θ 都变得特别低，甚至生成乱码，连SFT后基本的说话能力都没了

KL散度的 k1，k2，k3 估计

在推导逆向KL散度的求导时，我们需要构造无参数的分布 Q 和有参数的打分函数 g_θ 来完成变换：
$\mathbb{E}_{x\sim P_\theta(x)}[f_\theta(x)] = \mathbb{E}_{x\sim Q(x)}[g_\theta(x)]$

- 最简单的构造方法： $Q=\pi_{old}$ ，$g_\theta=\frac{\pi_\theta}{\pi_{old}}\log\frac{\pi_\theta}{\pi_{ref}}$ ，称为k1估计
- 我们依然令 $Q=\pi_{old}$ ，但 g_θ 还有其他构造方法，称为k2、k3估计

首先我们定义三个量：

- $k_1=-\log\frac{\pi_{ref}}{\pi_\theta}$
- $k_2=\frac{1}{2}\left(\log\frac{\pi_{ref}}{\pi_\theta}\right)^2$
- $k_3=\frac{\pi_{ref}}{\pi_\theta}-1-\log\frac{\pi_{ref}}{\pi_\theta}$

在off-policy下，我们依然设定无参数分布为 $Q=\pi_{old}$ ，则其他 g_θ 的构造方式为：

- k1估计（上一章介绍的）： $g_\theta=\frac{\pi_\theta}{\pi_{old}}k_1$
  - forward： $\mathbb{E}_{\pi_{old}}[\frac{\pi_\theta}{\pi_{old}}k_1]=\mathrm{KL}(\pi_\theta|\pi_{ref})$
  - backward： $\nabla_\theta\mathbb{E}_{\pi_{old}}[\frac{\pi_\theta}{\pi_{old}}k_1]=\mathbb{E}_{\pi_{old}}[\nabla_\theta\frac{\pi_\theta}{\pi_{old}}k_1]=\nabla_\theta\mathrm{KL}(\pi_\theta|\pi_{ref})$
  - 方差大，无偏
- k2估计： $g_\theta=\frac{\pi_{\theta.detach}}{\pi_{old}}k_2$
  - forward： $\mathbb{E}_{\pi_{old}}[\frac{\pi_{\theta.detach}}{\pi_{old}}k_2]\approx\mathrm{KL}(\pi_\theta|\pi_{ref})$
  - backward： $\nabla_\theta\mathbb{E}_{\pi_{old}}[\frac{\pi_{\theta.detach}}{\pi_{old}}k_2]=\mathbb{E}_{\pi_{old}}[\nabla_\theta\frac{\pi_{\theta.detach}}{\pi_{old}}k_2]=\nabla_\theta\mathrm{KL}(\pi_\theta|\pi_{ref})$
  - 方差小，forward有偏（但偏差很小，近似相等），backward无偏
- k3估计： $g_\theta=\frac{\pi_\theta}{\pi_{old}}k_3$
  - forward： $\mathbb{E}_{\pi_{old}}[\frac{\pi_\theta}{\pi_{old}}k_3]=\mathrm{KL}(\pi_\theta|\pi_{ref})$
  - backward： $\nabla_\theta\mathbb{E}_{\pi_{old}}[\frac{\pi_\theta}{\pi_{old}}k_3]=\mathbb{E}_{\pi_{old}}[\nabla_\theta\frac{\pi_\theta}{\pi_{old}}k_3]=\nabla_\theta\mathrm{KL}(\pi_\theta|\pi_{ref})$
  - 方差小，无偏，但计算麻烦一些

> 注1：k1，k2，k3的系数
>
> - k1、k3的系数都是 $\frac{\pi_\theta}{\pi_{old}}$ ，但k2的系数是 $\frac{\pi_{\theta.detach}}{\pi_{old}}$
> - 原因：
> - 虽然 $\mathbb{E}_{\pi_{old}}[\frac{\pi_\theta}{\pi_{old}}k_2]\approx\mathrm{KL}(\pi_\theta|\pi_{ref})$ ，但是 $\nabla_\theta\mathbb{E}_{\pi_{old}}[\frac{\pi_\theta}{\pi_{old}}k_2]\neq\nabla_\theta\mathrm{KL}(\pi_\theta|\pi_{ref})$ ，而且偏差很大不可忽略
> - 必须设置成 $\frac{\pi_{\theta.detach}}{\pi_{old}}$ 才能满足条件： $\mathbb{E}_{\pi_{old}}[\frac{\pi_{\theta.detach}}{\pi_{old}}k_2]\approx\mathrm{KL}(\pi_\theta|\pi_{ref})$ ，$\nabla_\theta\mathbb{E}_{\pi_{old}}[\frac{\pi_{\theta.detach}}{\pi_{old}}k_2]=\nabla_\theta\mathrm{KL}(\pi_\theta|\pi_{ref})$

> 注2：如何理解这三种估计：
>
> - 在单个样本下不相等：
>
> $$\frac{\pi_\theta}{\pi_{old}}k_1\neq\frac{\pi_\theta}{\pi_{old}}k_2\neq\frac{\pi_\theta}{\pi_{old}}k_3$$
>
> - 但在期望意义下相等（或近似相等）：

> - $\mathrm{KL}(\pi_\theta|\pi_{ref}) = \mathbb{E}_{\pi_{old}}[\frac{\pi_\theta}{\pi_{old}}k_1] = \mathbb{E}_{\pi_{old}}[\frac{\pi_\theta}{\pi_{old}}k_3] \approx \mathbb{E}_{\pi_{old}}[\frac{\pi_{\theta.detach}}{\pi_{old}}k_2]$
> - $\nabla_\theta \mathrm{KL}(\pi_\theta|\pi_{ref}) = \nabla_\theta \mathbb{E}_{\pi_{old}}[\frac{\pi_\theta}{\pi_{old}}k_1] = \nabla_\theta \mathbb{E}_{\pi_{old}}[\frac{\pi_\theta}{\pi_{old}}k_3] = \nabla_\theta \mathbb{E}_{\pi_{old}}[\frac{\pi_{\theta.detach}}{\pi_{old}}k_2]$
>
> （其中k2估计在forward是约等于，但在backward是等于）

> 注3：on-policy版本
>
> - 上述公式是在off-policy下给的。在on-policy下，把所有 π_{old} 换成 $\pi_{\theta.detach}$ 即可。
> - 为什么给的是off-policy公式：
> - k2估计的off-policy版本是 $g_\theta = \frac{\pi_{\theta.detach}}{\pi_{old}}k_2$ ，它比on-policy版本 $g_\theta = \frac{\pi_{\theta.detach}}{\pi_{\theta.detach}}k_2 = k_2$ 更本质

解释：什么是偏差、方差

偏差：$\mathbb{E}_{\pi_{old}}[g_\theta] = 偏差 + \mathrm{KL}(\pi_\theta|\pi_{ref})$

- k1、k3估计：
  - k1、k3 偏差=0，因此是$\mathbb{E}_{\pi_{old}}[...] = \mathrm{KL}(\pi_\theta|\pi_{ref})$
- k2 估计：
  - k2 偏差≠0，因此是 $\mathbb{E}_{\pi_{old}}[...] \approx \mathrm{KL}(\pi_\theta|\pi_{ref})$
  - 但是k2估计的偏差很小，是 $O(\mathrm{KL})^{1.5}$ 量级
  - 偏差可忽略的情况：在KL<1时， $O(\mathrm{KL})^{1.5} < \mathrm{KL}$ ，尤其在KL≈0时，这个偏差几乎可以忽略（强化学习中计算KL散度时，最初始 $\pi_{ref} = \pi_{old} = \pi_\theta$ ，因此KL散度本身是从0开始的。在更新后，只要它们相差不大，则KL散度也仍然只略高于0，这种情况k2是适用的）
  - 偏差不可忽略的情况：KL>1，此时 $O(\mathrm{KL})^{1.5} > \mathrm{KL}$ ，偏差急剧扩大。（对应训练崩溃，或者探索后离SFT的初始参数太远的情况），这种情况下k2估计的KL散度不仅无法正确约束，反而因为偏差过大而加剧崩溃。

方差：“期望=方差+采样平均”

- 这里 k1 方差大，而 k2、k3 方差小
  - 直观体现：KL散度是非负的，k2、k3同样也都是非负的，但k1有可能是负的
  - k1：在KL≈0时方差尤其严重
  - k2：用KL≈0时较小的偏差，换取低方差（k1无偏的代价是高方差），在实践中有可取之处。但KL较大时不适用
  - k3：暂时没看出为什么能同时做到无偏、低方差，应该会有其他方面的代价，可能是计算比k1、k2都复杂?

因为 k3 估计良好的性质（无偏，低方差），因此GRPO中一般使用它来代替KL散度

> verl中，估计KL散度的方式，对应 `actor_rollout_ref.actor.kl_loss_type` 。相应选项的解释：
>
> - `kl` : k1估计
> - `abs` ： 没见哪里用过
> - `mse` ： k2估计
> - `low_var_kl` k3估计
> - `full` ： 不知道是啥
> - `k1+` , `k3+` ： forward用k1、k3计算，但backward用k2计算。
>
> 使用建议：
>
> - verl官方建议使用 `low_var_kl` ，即k3
> - 有人反映verl的 `low_var_kl` 实现有错误，建议使用 `k3+`
> - https://github.com/verl-project/verl/pull/2953#issuecomment-3162113848
> - 实际：训练GRPO经常**不加**KL散度，GSPO和DAPO也淘汰了KL散度

k1+、k3+估计（为了修正某些代码实现的bug）

在on-policy时，k1,k2,k3估计的标准、正确实现是：

- forward： $\mathbb{E}_{\pi_{\theta.detach}}[\frac{\pi_\theta}{\pi_{\theta.detach}}k_1], \mathbb{E}_{\pi_{\theta.detach}}[\frac{\pi_\theta}{\pi_{\theta.detach}}k_3], \mathbb{E}_{\pi_{\theta.detach}}[k_2]$ （等于 $\mathbb{E}_{\pi_{\theta.detach}}[\frac{\pi_{\theta.detach}}{\pi_{\theta.detach}}k_2]$ ）
- backward： $\mathbb{E}_{\pi_{\theta.detach}}[\nabla_\theta\frac{\pi_\theta}{\pi_{\theta.detach}}k_1], \mathbb{E}_{\pi_{\theta.detach}}[\nabla_\theta\frac{\pi_\theta}{\pi_{\theta.detach}}k_3], \mathbb{E}_{\pi_{\theta.detach}}[\nabla_\theta k_2]$

某些代码库可能会提供一种简化的实现（实际有bug，是种错误实现）：

- forward：$\mathbb{E}_{\pi_{\theta.detach}}[k_1], \mathbb{E}_{\pi_{\theta.detach}}[k_3], \mathbb{E}_{\pi_{\theta.detach}}[k_2]$
- backward：$\mathbb{E}_{\pi_{\theta.detach}}[\nabla_\theta k_1], \mathbb{E}_{\pi_{\theta.detach}}[\nabla_\theta k_3], \mathbb{E}_{\pi_{\theta.detach}}[\nabla_\theta k_2]$

bug在哪：

- forward没问题：$\mathrm{KL}(\pi_\theta|\pi_{ref}) = \mathbb{E}_{\pi_{\theta.detach}}[\nabla_\theta k_1] = \mathbb{E}_{\pi_{\theta.detach}}[\nabla_\theta k_3] \approx \mathbb{E}_{\pi_{\theta.detach}}[\nabla_\theta k_2]$
- backward结果错误（k1,k3是错的，但k2正确）：
  - k1错误： $\mathbb{E}_{\pi_{\theta.detach}}[\nabla_\theta k_1] = 0 \neq \nabla_\theta \mathrm{KL}(\pi_\theta|\pi_{ref})$
  - k3错误： $\mathbb{E}_{\pi_{\theta.detach}}[\nabla_\theta k_3] = \nabla_\theta \mathrm{KL}(\pi_{ref}|\pi_\theta) \neq \nabla_\theta \mathrm{KL}(\pi_\theta|\pi_{ref})$
  - 只有k2是正确的： $\mathbb{E}_{\pi_{\theta.detach}}[\nabla_\theta k_2] = \nabla_\theta \mathrm{KL}(\pi_\theta|\pi_{ref})$

修正后的正确实现：

- forward：仍然是 $\mathbb{E}_{\pi_{\theta.detach}}[k_1], \mathbb{E}_{\pi_{\theta.detach}}[k_3], \mathbb{E}_{\pi_{\theta.detach}}[k_2]$
- backward：无论k1,k2,k3，backward结果统一设置成 $\mathbb{E}_{\pi_{\theta.detach}}[\nabla_\theta k_2]$
  - 因为 $\mathbb{E}_{\pi_{\theta.detach}}[\nabla_\theta k_2] = \nabla_\theta \mathrm{KL}(\pi_\theta|\pi_{ref})$ 是一种正确估计

- 这种人工为backward赋值的trick称为“直通估计器”

> verl的 k1+、k3+选项指的应该就是这回事，其原版实现可能有类似的bug，后来用这种实现打了补丁

KL散度的位置：单独的loss vs 合并进reward

> 结论：GRPO是放在单独的loss里，而不是放在reward里

直观解释：约束更加直接

比较KL散度出现在单独的loss中、合并进reward中的求导公式：

- loss中：$\nabla \text{目标函数} = \nabla \text{强化学习目标函数} - \nabla \mathrm{KL}$
  - KL散度也求了梯度，其对参数更新的约束效果很“明确”
- reward中：$\nabla \text{目标函数} = \nabla \text{强化学习目标函数} = \mathbb{E}_{\pi_{old}}[\frac{\pi_\theta}{\pi_{old}} A \cdot \nabla \log \pi_\theta]$
  - KL散度出现在A中（计算每个样本reward的时候）
  - 只使用了KL散度forward的值，而没有对KL散度求导
  - 因此KL散度对参数更新的约束效果是“间接”的，可能会被reward的其他部分抵消，而且还会导致reward设计困难（RL中reward设计本身就已经很困难了，平白无故又增加了难度）
- 总结：能直接求导的东西最好直接求导。实在没办法求导，才考虑放在reward里搞强化学习。

> 为什么PPO是k1并且放在reward里：可能是个历史遗留问题
>
> - 1.为什么放在reward里：
> - 猜测：当时的人没考虑过单独作为loss，后来才发现单独作为loss更好
> - 2.为什么使用k1，而不是k2、k3：
> - 猜测：k2、k3是后来才有的技术，PPO时代只有k1
> - 一种理论解释：单个样本虽然k1、k2、k3在估计**一批**样本的KL散度时无偏（或近似无偏），但在估计**单个**样本的KL散度（实际是“点对点信息差异”）时，只有k1是无偏的，而k2、k3都有偏（且偏差很大不能忽略）。作为单独的loss时是整体求期望，k2、k3的偏差可以抵消。但放在reward中，会和基于规则的reward纠缠在一起求方差，偏差无法抵消，因此需要KL散度在单个样本的粒度的无偏估计，只能使用k1.
> - 总结：PPO的选择只是个历史遗留问题，GRPO不要参考PPO

KL散度、策略熵、交叉熵

前面介绍了KL散度，这里顺便拓展策略熵、交叉熵的知识。

- 策略熵（或者简称“熵”）：$\mathrm{Entropy}(P) = \mathbb{E}_{x\sim P(x)}[-\log P(x)] = -\sum_{\text{遍历所有}x} P(x)\cdot \log P(x)$
  - $-\log P(x)$： 概率分布 P 下，样本 x 的最优编码长度（即信息量）
  - $\mathbb{E}_{x\sim P(x)}[-\log P(x)]$ ：概率分布 P 下，最优编码长度的**平均值**
  - P 分布越集中，熵越低：用少数较短的码处理高概率区即可
- 交叉熵：$\mathrm{CrossEntropy}(P||Q) = \mathbb{E}_{x\sim P(x)}[-\log Q(x)] = -\sum_{\text{遍历所有}x} P(x)\cdot \log Q(x)$
  - 从分布 P 采样，却使用分布 Q 的编码方案，导致的平均编码长度
- KL散度：$\mathrm{KL}(P||Q) = \mathbb{E}_{x\sim P(x)}\left[\log \frac{P(x)}{Q(x)}\right] = \mathrm{CrossEntropy}(P||Q) - \mathrm{Entropy}(P)$
  - KL散度=从P采样，用Q编码比用P编码，平均多出的编码长度
  - 交叉熵=从P采样，用Q编码的平均编码长度
  - 策略熵=从P采样，用P编码的平均编码长度
  - KL散度 = 交叉熵 - 策略熵

监督学习：极小化交叉熵=极小化KL散度

- 监督学习中， P 是数据本身的分布， Q 是模型输出的分布
- 数据分布 P 是固定的，其最优编码长度（策略熵）是个和模型无关的常数
- 因此 ∇策略熵=0， ∇交叉熵=∇KL散度
- 交叉熵的理论最小值=策略熵（此时∇交叉熵=0，KL散度取最小值=0）

强化学习：$\mathrm{KL}(\pi_\theta||\pi_{ref}) = \mathrm{CrossEntropy}(\pi_\theta||\pi_{ref}) - \mathrm{Entropy}(\pi_\theta)$
减小KL散度的两个动力学来源：

- 减小交叉熵：锚定效应，为了极小化 $\pi_\theta\cdot(-\log \pi_{ref})$ ，从 π_θ 中采样出的高概率样本在 π_{ref} 下不应该概率特别低
- 增大策略熵 $\mathrm{Entropy}(\pi_\theta)$： 让 π_θ
  保持探索能力，不要坍缩到几个高概率区（即防止“模式崩溃”）
- 交叉熵、策略熵搭配作为KL散度：如果不管策略熵，只用交叉熵，可能导致 π_θ 集中到 π_{ref} 的高概率区，这样采样出的 π_{ref} 确实大（从而交叉熵小），但集中到高概率区的结果是模式崩溃、一些概率较小的峰被抹平（灾难性遗忘）
- 有些算法会单独鼓励增大策略熵，以保持模型的探索能力